

Matriz de Extracción de Artículos Científicos

Información general del estudiante

- **Nombre del estudiante:** Ivett Anahi Zaragocin Mora
- **Técnica de IA:** Neuro-simbólico
- **Pregunta de investigación:** ¿Cómo combinan los enfoques neuro-simbólicos aprendizaje y razonamiento?

Matriz de extracción

Cadena de Búsqueda: ("neuro-symbolic."OR "neural-symbolic") AND "learning.^AND reasoning"

#	Referencia	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
1	Manhaeve, R., Dumančić, S., Kimmig, A., Demeester, T., & de Raedt, L. (2021). Neural probabilistic logic programming in DeepProbLog. ScienceDirect, 298, 103504. https://doi.org/10.1016/j.artint.2021.103504 [1]	2021	Science-Direct	Deep-ProbLog (programación lógica probabilística neural).	Integración de percepción de bajo nivel con razonamiento lógico de alto nivel.	Introducir un lenguaje que permita a las redes neuronales actuar como predicados probabilísticos en programas lógicos.	Extensión de ProbLog con "hechos neurales" entrenamiento basado en gradientes mediante inferencia compilada.	MNIST (adición), WAPs, CLUTRR.	Superó a CNNs en tareas de razonamiento de múltiples pasos y mostró alta capacidad de generalización.	El tiempo de conexión y compilación aumenta drásticamente con el tamaño del problema.	Provee un marco para manejar incertidumbre en la interfaz entre percepción y razonamiento.

#	Referencia	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
2	Khomich, Y. (2025). Neuro-Symbolic AI Systems: Bridging Logical Reasoning and Neural Networks for Future Intelligence. ResearchGate, 11, 621–625. [2]	2025	Research-Gate	Integración de razonamiento simbólico y redes neuronales.	Falta de transparencia, interpretabilidad y capacidad de razonamiento en modelos de aprendizaje profundo.	Explorar las implicaciones de la IA neuro-simbólica para avanzar en sistemas con entendimiento humano.	Análisis teórico basado en estudios de caso y proyecciones futuras de modelos computacionales híbridos.	No se encontró información en los documentos sobre este punto.	Identifica el potencial para superar la naturaleza de “caja negra” de los modelos actuales.	No se encontró información en los documentos sobre este punto.	Define los fundamentos teóricos para unir el aprendizaje basado en datos con la lógica formal.
3	Dong, H., Mao, J., Lin, T., Wang, C., Li, L., & Zhou, D. (2019). Neural Logic Machines. arXiv, 22. https://doi.org/10.48550/arXiv.1904.11694 [3]	2019	arXiv	Neural Logic Machines (NLM).	Limitaciones de generalización de las redes neuronales en tareas de razonamiento relacional.	Desarrollar una arquitectura capaz de inducir reglas de primer orden para razonamiento y toma de decisiones.	Representación de predicados como tensores y uso de cuantificadores lógicos diferenciales ($\forall, \exists$).	Blocks World, árboles genealógicos, grafos.	Logró 100 % de precisión en tareas de razonamiento y generalizó a problemas más grandes que los de entrenamiento.	Restringido a objetos constantes y escalabilidad limitada por el tamaño de los tensores.	Permite el aprendizaje de reglas lógicas abstractas aplicables a conteos variables de objetos.
4	Meenalochini, P. (2025). Neuro-Symbolic AI: Bridging Deep Learning and Symbolic Reasoning for Cognitive Computation. ResearchGate (Issue 9). [4]	2025	Research-Gate	IA Neuro-Simbólica (NSAI) integrada.	Las redes neuronales carecen de capacidad para razonamiento lógico, abstracción y generalización robusta.	Presentar un marco integral que combine percepción neuronal con módulos simbólicos para computación cognitiva.	Integración de estructuras lógicas (ontologías, grafos) en arquitecturas neuronales diferenciables.	VQA, razonamiento de grafos de conocimiento, modelos de diagnóstico.	Mejora la robustez, explicabilidad y eficiencia de datos en comparación con métodos puramente neuronales.	Desafíos en la escalabilidad y el mantenimiento de consistencia lógica en espacios neuronales de alta dimensión.	Propone un blueprint cognitivo para máquinas que puedan aprender y razonar como humanos.

#	Referencia	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
5	Garcez, A., Gori, M., Lamb, L. C., Serafini, L., Spranger, M., & Tran, S. N. (2019). Neural-symbolic computing: An effective methodology for principled integration of machine learning and reasoning. ResearchGate (Vol. 6, Issue 4). http://openaccess.city.ac.uk/id/eprint/22984/ [5]	2019	ResearchGate	Computación Neuro-Simbólica.	Necesidad de mecanismos de razonamiento y representación de conocimiento integrados con aprendizaje profundo.	Resumir logros recientes y proponer una metodología para la integración de aprendizaje y razonamiento.	Análisis de integración de aprendizaje neuronal con representación de conocimiento simbólico para explicabilidad.	Pascal dataset, ILP (programación lógica inductiva).	Demostró la efectividad de Logic Tensor Networks en interpretación de imágenes semánticas.	No se encontró información en los documentos sobre este punto.	Establece una metodología para construir sistemas de IA explicables y responsables.
6	Rani, M., Mishra, B. K., & Thakker, D. (2025). Advancing Symbolic Integration in Large Language Models: Beyond Conventional Neurosymbolic AI. ResearchGate, 54. https://doi.org/10.48550/arXiv.2510.21425 [6]	2025	ResearchGate	Integración de IA simbólica con Modelos de Lenguaje Extensos (LLMs).	Falta de factualidad, razonamiento fiel y explicabilidad en los LLMs actuales.	Evaluar métodos de integración para mejorar el razonamiento y la confiabilidad de los LLMs.	Revisión sistemática de literatura (SLR) siguiendo las directrices PRISMA 2020.	FOLIO, ProofWriter, GSM8K, WebQSP.	Las integraciones híbridas superan a modelos unimodales en tareas que requieren inferencia lógica.	Dependencia alta de las estrategias de planificación y sensibilidad a la calidad de los prompts lógicos.	Provee un roadmap para integrar solvers simbólicos y grafos de conocimiento con modelos generativos.

#	Referencia	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
7	Fu, R., Lyu, Y., Meng, C., Qi, M., Jin, Y., Zhao, Q., Bao, L., Gao, J., Shi, F., Dey, N., Luo, W., & Fong, S. (2026). NeuroSymb-MRG: Differentiable Abductive Reasoning with Active Uncertainty Minimization for Radiology Report Generation. ResearchGate, 12. https://doi.org/10.48550/arXiv.2603.01756 [7]	2026	ResearchGate	Razonamiento abductivo neuro-simbólico diferenciable.	Inconsistencia fáctica y falta de razonamiento clínico explícito en la generación automática de informes radiológicos.	Producir informes de radiología estructurados y fundamentados clínicamente integrando razonamiento abductivo.	Mapeo de imágenes a conceptos, cadenas lógicas diferenciables y refinamiento mediante agentes multi-agente.	IU X-ray, MIMIC-CXR.	Mejoras consistentes en métricas de lenguaje y consistencia fáctica sobre líneas base de encoder-decoder.	No se encontró información en los documentos sobre este punto.	Demuestra cómo la lógica abductiva puede proporcionar transparencia clínica en reportes médicos.
8	Delvecchio, G. P., Molfetta, L., & Moro, G. (2025). Neuro-Symbolic Artificial Intelligence: A Task-Directed Survey in the Black-Box Models Era. IJCAI International Joint Conference on Artificial Intelligence, 10418–10426. https://doi.org/10.24963/ijcai.2025/1157 [8]	2025	IJCAI	IA Neuro-Simbólica (NeSy).	Desafíos en la implementación práctica de métodos NeSy en escenarios complejos del mundo real.	Examinar avances específicos en tareas NeSy para explorar cómo la simbología mejora la explicabilidad.	Taxonomía dirigida a tareas integrando redes neuronales con componentes simbólicos como solvers o reglas.	WN18RR1, CLEVR, GQA, Caltech-UCSD Birds-200.	Identifica que la incorporación de restricciones de lógica de primer orden mejora la fidelidad del contenido en generación.	Ausencia de mecanismos de conteo y sesgo hacia ejemplos prototípicos en la generación restringida.	Categoriza métodos NeSy para aplicaciones reales en NLP y Visión por Computador.

#	Referencia	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
9	Sharifi, I., Wei, P., & Fallah, S. (2026). ANDRE: An Attention-based Neuro-symbolic Differentiable Rule Extractor. ResearchGate, 35. https://doi.org/10.48550/arXiv.2605.04193 [9]	2026	Research-Gate	ANDRE (Aprendizaje de reglas de primer orden diferenciable).	Automatización del descubrimiento de reglas basadas en cláusulas de Horn sobre datos estructurados.	Identificar conexiones faltantes entre entidades descubriendo patrones en relaciones existentes.	Búsqueda en anchura limitada para vecindarios y conversión de hechos relacionales en vectores neuronales.	Countries (S1-S3), Nations, UMLS, UW-CSE.	Superó a sistemas previos (NTP, NeuralLP) en precisión y eficiencia computacional en bases de conocimiento densas.	No se encontró información en los documentos sobre este punto.	Proporciona un trade-off práctico entre eficiencia computacional y capacidad de descubrimiento de reglas.
10	Mao, J., Tenenbaum, J. B., & Wu, J. (2026). Building Intelligent Agents with Neuro-Symbolic Concepts. ACM Digital Library, 69(2), 69–79. https://doi.org/10.1145/3715316 [10]	2026	ACM Digital Library	Neuro-Symbolic Concept Learner (NS-CL).	Necesidad de aprender conceptos visuales y parsing semántico a partir de supervisión natural (preguntas-respuestas).	Interpretar escenas y oraciones vinculando conceptos visuales con representaciones simbólicas ejecutables.	Razonamiento cuasi-simbólico que traduce lenguaje a programas ejecutables sobre detecciones de escena.	CLEVR.	Alta precisión en VQA y capacidad de transferencia de conceptos a nuevas tareas sin re-entrenamiento.	Requiere el diseño de un lenguaje específico de dominio (DSL) para la ejecución simbólica.	Demuestra el aprendizaje de conceptos visuales estructurados guiado por lenguaje natural.

#	Referencia	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
11	Bohne, T., Patricia Windler, A.-K., & Atzmueller, M. (2025). A Domain-Agnostic Neuro-Symbolic Architecture for Multimodal Human-in-the-Loop Anomaly Detection and Complex Fault Diagnosis. IEEE Xplore, 13, 210201–210236. https://doi.org/10.1109/ACCESS.2025.3641034 [11]	2025	IEEE Xplore	Arquitectura Neuro-Simbólica con Grafos de Conocimiento (KG) y Redes Neuronales.	Diagnóstico de fallos complejos y detección de anomalías multimodales en entornos industriales.	Proponer una arquitectura que combine percepción neuronal multimodal con razonamiento experto en KG.	Uso de SPARQL para recuperación de conocimiento experto y redes neuronales para análisis de señales de sensores.	4000 instancias de diagnóstico generadas aleatoriamente.	Capacidad de resolver problemas de diagnóstico complejos de forma sistemática y transparente.	Alta complejidad computacional al manejar fallos simultáneos interconectados.	Facilita la integración de expertos humanos en el bucle de diagnóstico mediante conocimiento estructurado.
12	Honda, H., & Hagiwara, M. (2021). Analogical Reasoning with Deep Learning-Based Symbolic Processing. IEEE Xplore, 9, 121859–121870. https://doi.org/10.1109/ACCESS.2021.3109443 [12]	2021	IEEE Xplore	Razonamiento analógico basado en Deep Learning y Prolog.	Limitaciones del razonamiento analógico tradicional ante la falta de correspondencia exacta en bases de conocimiento.	Desarrollar un motor de analogía que use aprendizaje profundo para realizar unificaciones flexibles (soft-unification).	Algoritmos de analogía de reglas y prueba de hipótesis integrando modelos neuronales y simbólicos.	Kinsources, IMDb, CLUTRR.	Logró extraer reglas lógicas y realizar analogías efectivas incluso con múltiples reglas para un mismo predicado.	Dificultad para inferir reglas bidireccionales si los términos no pueden ser analogizados.	Permite generar hipótesis y verificar reglas en bases de conocimiento mediante unificación neuronal.

#	Referencia	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
13	Serafini, L., & Garcez, A. d'Avila. (2016). Logic Tensor Networks: Deep Learning and Logical Reasoning from Data and Knowledge. arXi, 12. https://doi.org/10.48550/arXiv.1606.04422 [13]	2016	arXi	Logic Tensor Networks (LTN).	Integración de aprendizaje y razonamiento lógico sobre conjuntos de objetos con atributos cuantitativos.	Mapear símbolos lógicos a vectores en espacios reales para permitir inferencia rica y aprendizaje.	Inferencia mediante una pérdida de satisfacibilidad de restricciones lógicas en una estructura de tensores.	Friends and Smokers.	Demostró efectividad en completar bases de conocimiento inconsistentes y aprendizaje de representaciones semánticas.	No se encontró información en los documentos sobre este punto.	Unifica la lógica de primer orden con el aprendizaje profundo mediante optimización de satisfacibilidad.
14	Wu, Y., & Nakayama, H. (2024). MILE: Memory-Interactive Learning Engine for Neuro-Symbolic Solutions to Mathematical Problems. IEEE Xplore, 12, 134355–134365. https://doi.org/10.1109/ACCESS.2024.3461150 [14]	2024	IEEE Xplore	Memory-Interactive Learning Engine (MILE).	Resolución de problemas matemáticos que requieren mantenimiento de contexto a largo plazo.	Facilitar el mantenimiento de información a largo plazo mediante un "Memory Embedding Pool" para operandos.	Decodificación recurrente interactuando con un espacio de memoria unificado para constantes y números.	Math23K.	Logró resultados superiores a líneas base y mostró robustez ante el reemplazo de tokens de texto.	La precisión cae significativamente al aumentar el conteo de números o la longitud de las fórmulas.	Integra memoria externa para tratar operandos de diferentes orígenes de forma equitativa.
15	Maene, J., Leuven, K. U., & de Raedt, L. (2023). Soft-Unification in Deep Probabilistic Logic. NeuralP, 17. [15]	2023	NeurIPS	Deep-SoftLog (unificación suave en lógica probabilística profunda).	Dilema entre representaciones separadas o mapear símbolos a vectores en IA neuro-simbólica.	Extender ProbLog para permitir que términos embebidos se unifiquen basándose en similitud aprendida.	Introducción de una función de unificación suave mapeada a probabilidades de éxito.	Visual Sudoku, Countries link prediction.	La aproximación difusa superó a los sistemas actuales en clasificación de Sudoku visual.	No se encontró información en los documentos sobre este punto.	Combina el razonamiento probabilístico con similitudes semánticas en el espacio de embebimiento.

#	Referencia	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
16	Fitas, R. (2025). Neuro-Symbolic AI for Advanced Signal and Image Processing: A Review of Recent Trends and Future Directions. IEEE Xplore, 13, 143360–143376. https://doi.org/10.1109/ACCESS.2025.3598909 [16]	2025	IEEE Xplore	Revisión de técnicas NeSyAI.	Necesidad de superar las limitaciones de métodos puramente neuronales en interpretabilidad y generalización.	Proporcionar una revisión integral de técnicas NeSyAI aplicadas al procesamiento avanzado de señales e imágenes.	Revisión estructurada de literatura de 106 referencias entre 2018 y 2025.	Diabetes Pima, ClinicalKG, MoA-net.	Destaca ventajas de NeSyAI en adaptabilidad, robustez y reducción de la necesidad de grandes datasets etiquetados.	Complejidad computacional e integración de modelos heterogéneos.	Sintetiza tendencias futuras hacia una IA más explicable y adaptable.
17	Smirnov, A., Ponomarev, A., & Agafonov, A. (2024). Ontology-Based Neuro-Symbolic AI: Effects on Prediction Quality and Explainability. IEEE Xplore, 12, 156609–156626. https://doi.org/10.1109/ACCESS.2024.3485185 [17]	2024	IEEE Xplore	IA Neuro-Simbólica basada en ontologías.	Falta de interpretabilidad para expertos de dominio en las predicciones de redes neuronales.	Evaluar el efecto de integrar ontologías en la calidad de predicción y la explicabilidad para el usuario.	Uso de funciones de pérdida basadas en ontologías para forzar la extracción de conceptos con significado semántico.	XTRAINS, SCDB.	Las explicaciones basadas en ontologías mejoran la comprensión del usuario y la eficiencia de la interacción.	La incrustación de definiciones lógicas no siempre mejora la calidad de predicción dependiendo de la ontología.	Mejora la transparencia al proporcionar pistas comprensibles para la toma de decisiones crítica.
18	Kim, Y. (2025). Standard Neural Computation Alone Is Insufficient for Logical Intelligence. ResearchGate, 14. https://doi.org/10.48550/arXiv.2502.02135 [18]	2025	ResearchGate	IA Neuro-Simbólica (LNU - Logic Neural Units).	Insuficiencia de la computación neuronal estándar para lograr inteligencia lógica robusta.	Demostrar la necesidad de integrar componentes simbólicos para alcanzar razonamiento lógico de tipo humano.	Análisis comparativo de límites de decisión entre lógica dura, NLU y MLPs estándar.	No se encontró información en los documentos sobre este punto.	El aumento del parámetro de gating ayuda a que las redes neuronales aproximen la lógica dura.	No se encontró información en los documentos sobre este punto.	Argumenta que la computación simbólica es esencial para avanzar hacia la inteligencia general.

#	Referencia	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
19	Yang, Z., Lee, J., Baral, C., Li, B., & Yang, Y. (2023). Neuro-Symbolic AI Approaches to Enhance Deep Neural Networks with Logical Reasoning and Knowledge Integration. ProQuest, 24. https://doi.org/30490270 [19]	2023	Arizona State Univ.	NeurASP, iSTE, Recurrent Transformer.	Los modelos de aprendizaje profundo son voraces en datos y difíciles de integrar con conocimiento explícito.	Proponer enfoques NeSy para dotar a las redes neuronales de capacidades de razonamiento lógico y justificación.	Combinación de redes neuronales con Programación de Conjuntos de Respuesta (ASP) y optimización diferenciable.	MNIST Addition, Sudoku, bAbI, Step-Game, gSCAN.	NeurASP superó líneas base en tareas de razonamiento complejo y manejó tareas de planificación que LLMs solos fallan.	No se encontró información en los documentos sobre este punto.	Desarrolla métodos para integrar conocimiento explícito y lógica en arquitecturas profundas.
20	Colelough, B. C., & Regli, W. (2024). Neuro-Symbolic AI in 2024: A Systematic Review. ResearchGate, 12. https://doi.org/10.48550/arXiv.2501.05435 [20]	2024	CEUR Workshop	Revisión Sistemática de NeSyAI.	Identificación de brechas actuales en la literatura tras la explosión de investigación entre 2020-2024.	Proporcionar una visión del panorama de proyectos de IA neuro-simbólica y donde se enfocan los esfuerzos de calidad.	Metodología PRISMA analizando 167 artículos con bases de código asociadas.	No se encontró información en los documentos sobre este punto.	La mayoría del esfuerzo del aprendizaje e inferencia (63 %), con menor enfoque en confiabilidad (28 %).	Existe una representación escasa de la metacognición (solo 5 % de los estudios).	Identifica oportunidades interdisciplinarias para integrar explicabilidad en todas las áreas de investigación.

Referencias

- [1] R. Manhaeve, S. Dumančić, A. Kimmig, T. Demeester, and L. D. Raedt, “Neural probabilistic logic programming in deepproblog,” *Science Direct*, vol. 298, p. 103504, 9 2021.
- [2] Y. Khomich, “Neuro-symbolic ai systems: Bridging logical reasoning and neural networks for future intelligence,” *ResearchGate*, vol. 11, pp. 621–625, 2025.
- [3] H. Dong, J. Mao, T. Lin, C. Wang, L. Li, and D. Zhou, “Neural logic machines,” *arXiv*, p. 22, 4 2019. [Online]. Available: <http://arxiv.org/abs/1904.11694>
- [4] P. Meenalochini, “Neuro-symbolic ai: Bridging deep learning and symbolic reasoning for cognitive computation,” *ResearchGate*, vol. 9, pp. 1–12, 5 2025.
- [5] A. Garcez, M. Gori, L. C. Lamb, L. Serafini, M. Spranger, and S. N. Tran, “Neural-symbolic computing: An effective methodology for principled integration of machine learning and reasoning,” *ResearchGate*, vol. 6, pp. 611–632, 2019. [Online]. Available: <http://openaccess.city.ac.uk/id/eprint/22984/http://openaccess.city.ac.uk/>
- [6] M. Rani, B. K. Mishra, and D. Thakker, “Advancing symbolic integration in large language models: Beyond conventional neurosymbolic ai,” *ResearchGate*, p. 54, 10 2025. [Online]. Available: <http://arxiv.org/abs/2510.21425>
- [7] R. Fu, Y. Lyu, C. Meng, M. Qi, Y. Jin, Q. Zhao, L. Bao, J. Gao, F. Shi, N. Dey, W. Luo, and S. Fong, “Neurosymb-mrg: Differentiable abductive reasoning with active uncertainty minimization for radiology report generation,” *ResearchGate*, p. 12, 4 2026. [Online]. Available: <http://arxiv.org/abs/2603.01756>
- [8] G. P. Delvecchio, L. Molfetta, and G. Moro, “Neuro-symbolic artificial intelligence: A task-directed survey in the black-box models era,” in *IJCAI International Joint Conference on Artificial Intelligence*. International Joint Conferences on Artificial Intelligence, 2025, pp. 10 418–10 426.
- [9] I. Sharifi, P. Wei, and S. Fallah, “Andre: An attention-based neuro-symbolic differentiable rule extractor,” *ResearchGate*, p. 35, 5 2026. [Online]. Available: <http://arxiv.org/abs/2605.04193>
- [10] J. Mao, J. B. Tenenbaum, and J. Wu, “Building intelligent agents with neuro-symbolic concepts,” *ACM Digital Library*, vol. 69, pp. 69–79, 2 2026.
- [11] T. Bohne, A.-K. P. Windler, and M. Atzmueller, “A domain-agnostic neuro-symbolic architecture for multimodal human-in-the-loop anomaly detection and complex fault diagnosis,” *IEEE Access*, vol. 13, pp. 210 201–210 236, 12 2025.
- [12] H. Honda and M. Hagiwara, “Analogical reasoning with deep learning-based symbolic processing,” *IEEE Explore*, vol. 9, pp. 121 859–121 870, 8 2021.
- [13] L. Serafini and A. d’Avila Garcez, “Logic tensor networks: Deep learning and logical reasoning from data and knowledge,” *arXi*, p. 12, 7 2016. [Online]. Available: <http://arxiv.org/abs/1606.04422>
- [14] Y. Wu and H. Nakayama, “Mile: Memory-interactive learning engine for neuro-symbolic solutions to mathematical problems,” *IEEE Xplore*, vol. 12, pp. 134 355–134 365, 9 2024.
- [15] J. Maene, K. U. Leuven, and L. D. Raedt, “Soft-unification in deep probabilistic logic,” *NeuralP*, p. 17, 2023.

- [16] R. Fitas, “Neuro-symbolic ai for advanced signal and image processing: A review of recent trends and future directions,” *IEEE Access*, vol. 13, pp. 143 360–143 376, 2025.
- [17] A. Smirnov, A. Ponomarev, and A. Agafonov, “Ontology-based neuro-symbolic ai: Effects on prediction quality and explainability,” *IEEE Access*, vol. 12, pp. 156 609–156 626, 10 2024.
- [18] Y. Kim, “Standard neural computation alone is insufficient for logical intelligence,” *ResearchGate*, p. 14, 2 2025. [Online]. Available: <http://arxiv.org/abs/2502.02135>
- [19] Z. Yang, J. Lee, C. Baral, B. Li, and Y. Yang, “Neuro-symbolic ai approaches to enhance deep neural networks with logical reasoning and knowledge integration,” *ProQuest*, p. 24, 8 2023.
- [20] B. C. Colelough and W. Regli, “Neuro-symbolic ai in 2024: A systematic review,” *ResearchGate*, p. 12, 8 2024. [Online]. Available: <https://brandoncolelough.com/>