

Descripción del Problema Técnico

Nombre: Ivett Anahi Zaragocin Mora

Fecha: 29/04/2026

Ciclo: Cuarto

Técnica de IA: Neuro-simbólico

Pregunta de investigación: ¿Cómo combinan los enfoques neuro-simbólicos aprendizaje y razonamiento?

1. Contexto general del problema

En el ámbito de los **Sistemas Inteligentes** y la Ciencia de la Computación, la inteligencia artificial busca construir agentes capaces de aprender conocimiento nuevo de sus experiencias para aplicarlo de manera flexible al razonamiento en múltiples tareas y entornos [1]. El desafío actual reside en integrar el procesamiento de "Sistema 1" (rápido e intuitivo), modelado eficientemente por el aprendizaje profundo, con el "Sistema 2" (lento y lógico), propio del razonamiento simbólico [2]. Este entorno de investigación es crítico para el desarrollo de aplicaciones en robótica cognitiva, comprensión de escenas visuales y resolución de problemas matemáticos aplicados [3].

2. Situación actual basada en evidencia

Diversos estudios evidencian que el **aprendizaje profundo** sobresale en tareas de percepción como la visión y el habla, pero opera frecuentemente como una "caja negra" que carece de transparencia y es altamente dependiente de grandes volúmenes de datos etiquetados [4]. Por otro lado, autores indican que los **sistemas simbólicos** tradicionales son eficaces en la deducción lógica y el razonamiento abstracto, pero presentan dificultades para adaptarse a la complejidad de los datos brutos del mundo real[4]. Recientemente, métodos como el *Chain-of-Thought* en modelos de lenguaje intentan simular razonamiento, pero sufren de inconsistencias y errores aritméticos debido al desajuste entre el modelado probabilístico y la precisión requerida en cálculos simbólicos. [5]

3. Brecha o vacío identificado

A pesar de los avances, existe una brecha significativa en la unión de la flexibilidad del razonamiento probabilístico de alto nivel con el poder representacional de las redes neuronales profundas, lo cual se mantiene como un problema abierto [3]. Específicamente, muchas representaciones de fórmulas en la resolución de problemas matemáticos se limitan a estructuras de árbol que no son Turing-completas y no soportan el uso de variables referenciadas múltiples veces[5]. Además, persiste una incapacidad en

los modelos puramente neuronales para proporcionar justificaciones o explicaciones que los expertos de dominio puedan entender o modificar[3].

4. Problema central

El problema radica en la **difícultad técnica de integrar el aprendizaje basado en datos con la toma de decisiones basada en reglas lógicas** en una única arquitectura cohesiva que permita realizar razonamientos de múltiples pasos y resolver el problema de la conexión de símbolos (*symbol grounding*)[2]. Esta falta de integración limita la construcción de agentes inteligentes que puedan razonar y aprender simultáneamente aprovechando las fortalezas de ambos paradigmas[3].

5. Consecuencias o impacto

Esta situación genera consecuencias como la creación de sistemas "hambrientos de datos" (*data-hungry*) que requieren supervisión masiva y son propensos a fallar ante desviaciones mínimas en la distribución de entrenamiento[4]. Asimismo, la opacidad en la toma de decisiones plantea riesgos en aplicaciones críticas como el diagnóstico médico o la seguridad industrial[3], [4]. Finalmente, la falta de una estructura lógica explícita limita la capacidad de generalización composicional y la transferencia de conocimiento a nuevas tareas sin entrenamiento adicional[1].

6. Actores involucrados

Los principales actores involucrados incluyen investigadores en inteligencia artificial relacional estadística, desarrolladores de sistemas de procesamiento de lenguaje natural y expertos en dominios específicos como la salud y la robótica[3]. También se identifican como partes interesadas las organizaciones que requieren modelos de IA explicables y adaptables para la resolución de problemas complejos[3], [5].

7. Variables o elementos clave

Las variables clave asociadas al problema incluyen:

- **Representaciones subsimbólicas:** Pesos y *embeddings* de redes neuronales que procesan datos no estructurados[4].
- **Representaciones simbólicas:** Reglas lógicas, programas funcionales y lenguajes de dominio específico (DSL)[1].
- **Interfaz neuro-simbólica:** Mecanismos de diferenciación y optimización que vinculan la lógica con el aprendizaje (ej. predicados neuronales o pérdida semántica)[4].
- **Interfaz neuro-simbólica:** Mecanismos de diferenciación y optimización que vinculan la lógica con el aprendizaje[1].

8. Delimitación del problema

El presente problema se delimita al desarrollo y evaluación de formalismos neuro-simbólicos específicos como DeepProbLog, NeurASP, MILE y el Aprendiz de Conceptos Neuro-Simbólicos (NS-CL)[5]. Se centra en aplicaciones de razonamiento relacional, comprensión de escenas visuales y resolución de problemas matemáticos, excluyendo enfoques de razonamiento puramente simbólico que no integren capacidades de percepción neuronal o métodos que no soporten programas recursivos y complejos[4].

9. Vinculación con la sublínea de investigación

Este problema se enmarca dentro de la sublínea de investigación de **Sistemas Inteligentes y Aprendizaje Automático**, debido a su enfoque en la creación de interfaces potentes entre la lógica y las redes neuronales para superar las limitaciones de los métodos actuales de aprendizaje de extremo a extremo (*end-to-end*)[2].

Referencias:

- [1] J. Mao, J. B. Tenenbaum, and J. Wu, “Building Intelligent Agents with Neuro-Symbolic Concepts,” *Commun. ACM*, vol. 69, no. 2, pp. 69–79, Feb. 2026, doi: 10.1145/3715316.
- [2] Z. Yang, J. Lee, C. Baral, B. Li, and Y. Yang, “Neuro-Symbolic AI Approaches to Enhance Deep Neural Networks with Logical Reasoning and Knowledge Integration,” *ProQuest*, Aug. 2023. doi: 30490270.
- [3] Y. Khomich, “Neuro-Symbolic AI Systems: Bridging Logical Reasoning and Neural Networks for Future Intelligence,” *International Journal Of Advance Research And Innovative Ideas In Education*, 2025. ISSN: 2395-4396.
- [4] R. Manhaeve, S. Dumančić, A. Kimmig, T. Demeester, and L. De Raedt, “Neural probabilistic logic programming in DeepProbLog,” *Artif. Intell.*, vol. 298, Sep. 2021, doi: 10.1016/j.artint.2021.103504.
- [5] Y. Wu and H. Nakayama, “MILE: Memory-Interactive Learning Engine for Neuro-Symbolic Solutions to Mathematical Problems,” *IEEE Access*, vol. 12, pp. 134355–134365, 2024, doi: 10.1109/ACCESS.2024.3461150.